

TRABAJO FINAL DE MÁSTER

Máster en Data Analytics

Marketing Data-Driven en Fintech:

Análisis de campañas de telemarketing y modelo predictivo
de contratación de depósitos a plazo

Ricardo - Marc - Ángel - Pablo

2026

ÍNDICE

1. Introducción

- 1.1 Descripción general del proyecto
- 1.2 Objetivos del proyecto
- 1.3 Finalidad del proyecto

2. Descripción de los datos

- 2.1 Origen y naturaleza del dataset
- 2.2 Estructura de las variables
- 2.3 Variable objetivo
- 2.4 Calidad de los datos
- 2.5 Contexto macroeconómico

3. Desarrollo del proyecto

- 3.1 Enfoque metodológico
- 3.2 Limpieza y preparación de los datos
- 3.3 Análisis exploratorio de datos
- 3.4 Análisis de correlaciones
- 3.5 Definición de KPIs
- 3.6 Modelado predictivo
- 3.7 Cuadro de mando ejecutivo

4. Resultados

- 4.1 Hallazgos del análisis exploratorio
- 4.2 Resultados de los modelos predictivos
- 4.3 Interpretación de los modelos
- 4.4 Cuadro de mando ejecutivo

5. Conclusiones y discusión

- 5.1 Síntesis de hallazgos
- 5.2 Sobre los modelos predictivos
- 5.3 Limitaciones
- 5.4 Recomendaciones estratégicas
- 5.5 Oportunidades de desarrollo a futuro

6. Bibliografía

1. INTRODUCCIÓN

1.1 Descripción general del proyecto

El sector financiero opera en un entorno cada vez más competitivo y digitalizado. Las entidades bancarias necesitan captar y fidelizar clientes mediante estrategias de marketing que resulten eficientes en costes y, al mismo tiempo, efectivas en resultados. Las campañas de marketing directo basadas en contacto telefónico siguen siendo un canal habitual para la comercialización de productos financieros, especialmente en mercados donde la relación personal con el cliente mantiene un peso significativo en la decisión de compra.

La rentabilidad de estas campañas depende, en gran medida, de la capacidad de la entidad para dirigir sus esfuerzos hacia los segmentos de clientes con mayor probabilidad de conversión. Contactar de forma indiscriminada no solo incrementa los costes operativos, sino que reduce la eficacia global de la acción comercial y deteriora la experiencia del cliente.

El presente Trabajo Final de Máster aborda este problema a partir de un caso real. Se analizan los datos generados por las campañas de telemarketing de una entidad bancaria portuguesa, recogidos entre mayo de 2008 y noviembre de 2010. El dataset procede del repositorio UCI Machine Learning (Moro et al., 2014) y ha sido ampliamente referenciado en la literatura académica sobre clasificación binaria y marketing bancario. El producto comercializado es un depósito a plazo fijo. El conjunto de datos incluye información demográfica de los clientes, su situación financiera, las características del contacto comercial y un conjunto de indicadores macroeconómicos vigentes en el momento de cada interacción.

Con 41.188 registros y 21 variables, el volumen permite abordar análisis estadísticos con margen suficiente, si bien la distribución de la variable objetivo presenta un desbalance pronunciado: apenas un 11,3% de los contactos resultaron en contratación efectiva. Esta asimetría condiciona tanto el análisis exploratorio como la estrategia de modelado, y se aborda de forma explícita a lo largo del proyecto.

El enfoque adoptado es integral: parte de la exploración y el tratamiento de los datos, avanza hacia el análisis de correlaciones y la identificación de variables relevantes, y culmina con la construcción de modelos predictivos y un cuadro de mando orientado a la toma de decisiones.

1.2 Objetivos del proyecto

El objetivo general de este trabajo es convertir los datos históricos de campaña en conocimiento que permita a la entidad optimizar sus futuras estrategias de captación. Para ello, se plantearon cinco objetivos específicos:

1. Comprender el perfil del cliente susceptible de contratación, analizando las variables demográficas, socioeconómicas y financieras que diferencian a quienes aceptan el producto de quienes lo rechazan.
2. Evaluar la influencia del contexto macroeconómico. Indicadores como la tasa de empleo, el índice de confianza del consumidor, el índice de precios al consumo o el euríbor a tres meses condicionan la percepción de riesgo y la propensión al ahorro. Su incorporación aporta una dimensión explicativa que trasciende el perfil individual del cliente.
3. Definir indicadores clave de rendimiento (KPIs) que permitan monitorizar la eficacia de las campañas de forma continua y comparable: tasa de conversión global, conversión segmentada por perfil y canal, distribución temporal de la efectividad y relación entre intensidad de contacto y resultado.
4. Diseñar un cuadro de mando ejecutivo que sintetice los hallazgos en visualizaciones claras, pensadas para perfiles de decisión no técnicos.
5. Desarrollar un modelo predictivo de probabilidad de contratación que permita priorizar los contactos con mayor expectativa de conversión y reducir el coste por adquisición.

1.3 Finalidad del proyecto

Cuando la tasa de conversión apenas supera el once por ciento de los contactos realizados, la capacidad de anticipar el comportamiento del cliente deja de ser una ventaja marginal.

Cada llamada dirigida a un cliente con baja probabilidad de contratación supone un coste de oportunidad concreto: tiempo del equipo comercial, saturación del cliente y deterioro de la percepción de marca. Este proyecto busca demostrar cómo un enfoque basado en datos, aplicado con rigor metodológico, puede convertir un proceso de captación masivo e indiscriminado en una estrategia segmentada y eficiente.

La combinación de análisis exploratorio, modelización predictiva y visualización ejecutiva refleja el ciclo completo de un proyecto analítico real: desde la pregunta de negocio hasta la recomendación estratégica. El trabajo integra tratamiento de datos, análisis estadístico,

construcción de modelos y comunicación de resultados en un caso con relevancia empresarial directa, en línea con las competencias del Máster en Data Analytics.

2. DESCRIPCIÓN DE LOS DATOS

2.1 Origen y naturaleza del dataset

El conjunto de datos procede del repositorio UCI Machine Learning Repository y fue recopilado a partir de las campañas de marketing directo de una entidad bancaria portuguesa. Los registros corresponden a llamadas telefónicas realizadas entre mayo de 2008 y noviembre de 2010, período que coincide con la fase más aguda de la crisis financiera global y con el inicio de la crisis de deuda soberana en la zona euro. Esta coincidencia temporal condiciona de forma directa el comportamiento de los clientes, la percepción de riesgo y los resultados de las campañas.

El dataset contiene 41.188 registros y 21 variables. Cada registro representa un contacto telefónico con un cliente al que se le ofrece la contratación de un depósito a plazo fijo. La variable objetivo (*y* en el dataset original) registra si el cliente aceptó o rechazó la oferta. Un mismo cliente puede aparecer en más de un registro si fue contactado en varias ocasiones a lo largo de la campaña.

2.2 Estructura de las variables

Las 21 variables se organizan en cuatro bloques temáticos, resumidos en la siguiente tabla:

Bloque	Variables	Descripción
Perfil demográfico	<i>age, job, marital, education</i>	Edad, ocupación (12 categorías), estado civil y nivel educativo (8 niveles)
Situación financiera	<i>default, housing, loan</i>	Impago crediticio, hipoteca vigente y préstamo personal. Admiten valor "unknown"
Contacto comercial	<i>contact, month, day_of_week, duration, campaign, pdays, previous, poutcome</i>	Canal, momento, duración, frecuencia de contacto y resultado de campaña previa
Indicadores macro	<i>emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed</i>	Tasa empleo, IPC, confianza consumidor, euribor 3M y número empleados

El bloque macroeconómico merece atención particular. La tasa de variación del empleo osciló entre -3,4 y 1,4. El índice de precios al consumo se situó entre 92,2 y 94,8 (base 2010 = 100). El índice de confianza del consumidor registró valores exclusivamente negativos durante todo el período (de -50,8 a -26,9), evidencia del pesimismo sostenido de los hogares portugueses. El euríbor a tres meses varió entre 0,63 y 5,05, reflejando las intervenciones del BCE. El número de empleados se mantuvo entre 4.963 y 5.228.

2.3 Variable objetivo

La variable objetivo es la contratación del depósito a plazo (*y*, recodificada como *subscribed_term_deposit* tras la limpieza). Es binaria: "yes" si el cliente aceptó, "no" en caso contrario.

Su distribución presenta un desbalance considerable: 36.548 registros (88,7%) corresponden a rechazos frente a 4.640 (11,3%) de contrataciones. Esta proporción, habitual en campañas de marketing directo, obliga a prestar atención especial a las métricas de la clase minoritaria. Un modelo que clasifique todos los registros como "no" alcanzaría una exactitud aparente del 88,7% sin aportar capacidad predictiva alguna.

2.4 Calidad de los datos

No se detectaron valores nulos en ninguna de las 21 variables. Sin embargo, varias variables categóricas codifican la ausencia de información como "unknown".

La siguiente tabla resume la distribución de estos valores:

Variable	Registros unknown	Porcentaje
<i>default</i>	8.597	20,9%
<i>education</i>	1.731	4,2%
<i>housing</i>	990	2,4%
<i>loan</i>	990	2,4%
<i>job</i>	330	0,8%
<i>marital</i>	80	0,2%

El caso más relevante es *default*, donde el porcentaje de desconocidos es suficiente para comprometer la capacidad discriminante de la variable. Se identificaron 12 registros duplicados, que se eliminaron conservando la primera aparición, resultando un dataset de 41.176 registros.

La variable *pdays* merece atención particular: el 96,3% de los registros contiene el valor 999, un marcador que indica ausencia de contacto en campañas previas. No es una medida temporal real, sino un código categórico que se trató como tal en el análisis.

La variable *duration* plantea un dilema metodológico conocido en este dataset: su valor solo se conoce tras finalizar la llamada, por lo que no está disponible como predictor antes del contacto. Se mantuvo en el análisis exploratorio por su valor descriptivo, y su impacto en los modelos se discute en la sección de limitaciones.

2.5 Contexto macroeconómico

El período 2008-2010 abarca la crisis financiera global, la crisis de deuda soberana europea y las primeras fases del ajuste fiscal en Portugal. Los indicadores macroeconómicos del dataset reflejan esta coyuntura y se seleccionaron por su complementariedad:

- Índice de Confianza del Consumidor: mide el sentimiento de los hogares respecto a la situación económica. Se mantuvo en terreno negativo durante todo el período, reflejando el pesimismo generalizado. Fuente: Comisión Europea (DG ECFIN).
- Índice de Precios al Consumo (CPI): mide la evolución del nivel de precios con base 2010 = 100. Se mantuvo relativamente estable, con inflación contenida acorde con el entorno recesivo. Fuente: INE Portugal.
- Tasa de Ocupación (*employment-to-population ratio*): porcentaje de población en edad laboral empleada. Se eligió sobre la tasa de paro convencional porque no depende de la población activa, evitando distorsiones por desánimo laboral en períodos de crisis. Fuente: Banco de Portugal (BPstat).
- Euríbor a 3 meses: tipo de interés interbancario de referencia en la zona euro. Registró una caída progresiva desde niveles superiores al 5% hasta valores por debajo del 1%, consecuencia de la política monetaria expansiva del BCE. Fuente: European Money Markets Institute (EMMI).

Incluir estas variables permite evaluar hasta qué punto el éxito de una campaña depende no solo de las características del cliente o de la ejecución comercial, sino del entorno económico en el que opera la entidad.

3. DESARROLLO DEL PROYECTO

3.1 Enfoque metodológico

El proyecto sigue un flujo analítico secuencial en cinco fases:

- Limpieza y preparación de los datos.
- Análisis exploratorio de datos (EDA) en cuatro dimensiones: demográfica, financiera, contacto y macroeconómica.
- Análisis de correlaciones: Spearman para variables numéricas, Chi-cuadrado y V de Cramér para categóricas.
- Modelado predictivo: regresión logística, XGBoost y regresión logística reducida.
- Diseño del cuadro de mando ejecutivo en Power BI.

Cada fase se apoya en los resultados de la anterior, de modo que las decisiones tomadas en etapas tempranas quedan documentadas antes de avanzar.

El entorno técnico es Python, con librerías especializadas en manipulación de datos (pandas, numpy), análisis estadístico (scipy, statsmodels, scikit-learn) y visualización (matplotlib, seaborn, plotly). Las funciones reutilizables se agruparon en un módulo independiente (*funciones.py*) para facilitar la reproducibilidad. El cuadro de mando se desarrolló en Power BI a partir de ficheros CSV exportados desde Python.

3.2 Limpieza y preparación de los datos

El proceso de limpieza incluyó las siguientes operaciones:

- Eliminación de 12 registros duplicados, reduciendo el dataset a 41.176 observaciones.
- Renombrado de columnas para mejorar la legibilidad: *duration* a *last_contact_duration_secs*, *campaign* a *number_contacts*, y a *subscribed_term_deposit*.
- Normalización de textos a minúsculas, eliminación de espacios residuales y unificación de separadores. Reclasificación de "admin" como "administrative_staff".
- Creación de variables derivadas: edad en seis tramos (17-25, 26-35, 36-45, 46-55, 56-65, 65+), duración en siete intervalos (de 0-1 min a >20 min), e intervalos de indicadores macro definidos a partir de su distribución.

- Conversión de variables categóricas al tipo correspondiente con orden explícito. Recodificación de la variable objetivo a binario (1/0).

3.3 Análisis exploratorio de datos

El análisis exploratorio se organizó en cuatro ejes.

A continuación se resumen las estadísticas descriptivas clave:

Variable	Media	Mediana	Rango / Detalle
Edad	40,0 años	38	17 - 98 años (desv. típ. 10,4)
Duración llamada	258 s (4,3 min)	180 s (3,0 min)	0 - 4.918 s
Contactos campaña	2,57	2	1 - 56
Contactos previos	0,17	0	96,3% sin contacto previo

El grueso de la base de clientes se concentra entre los 26 y los 45 años. Las ocupaciones más representadas son personal administrativo (25,3%), trabajadores de construcción (22,5%) y técnicos (16,4%). El estado civil predominante es casado (60,5%), seguido de soltero (28,1%). En educación, la categoría más frecuente es grado universitario (29,5%), seguida de bachillerato (23,1%).

Respecto a la situación financiera, la gran mayoría no presenta impagos registrados, aunque el 20,9% de valores desconocidos en *default* limita la utilidad de esta variable. Aproximadamente el 52,4% dispone de hipoteca y el 15,2% tiene préstamo personal activo.

El canal predominante es el teléfono móvil (63,5% de las interacciones). El 96,3% de los clientes no había sido contactado en campañas previas, lo que limita la información histórica disponible para modelar el comportamiento.

3.4 Análisis de correlaciones

Se emplearon dos métodos complementarios para evaluar la relación entre las variables explicativas y la variable objetivo.

Para las variables numéricas se calculó el coeficiente de Spearman, que mide asociación monótona sin asumir linealidad.

Los resultados más relevantes:

Variable	Coefficiente ρ	Interpretación
<i>duration</i>	0,349	Correlación positiva moderada: mayor duración, mayor contratación
<i>nr.employed</i>	-0,284	Menos empleo asociado a más contratación (efecto refugio)
<i>euribor3m</i>	-0,267	Tipos bajos asociados a más contratación
<i>emp.var.rate</i>	-0,247	Deterioro laboral asociado a más contratación
<i>previous</i>	0,200	Contacto previo favorece contratación
<i>age</i>	-0,012	Sin correlación relevante

Para las variables categóricas se aplicó el test de Chi-cuadrado de independencia, complementado con la V de Cramér como medida del tamaño del efecto (escala 0-1). Los resultados más destacados:

Variable	V de Cramér	p-valor	Significación
<i>euribor3m</i> (agrupado)	0,411	< 0,001	Fuerte
<i>previous contacts</i>	0,411	< 0,001	Fuerte
<i>cons.conf.idx</i> (agrupado)	0,382	< 0,001	Fuerte
<i>duration</i> (agrupada)	0,292	< 0,001	Moderada-fuerte
<i>cons.price.idx</i> (agrupado)	0,258	< 0,001	Moderada
<i>credit_default</i>	0,012	0,057	No significativa
<i>housing_loan</i>	0,005	0,577	No significativa

Las variables financieras (*default*, *housing*, *loan*) muestran asociaciones débiles o no significativas, especialmente con el volumen de valores desconocidos que presentan. El doble enfoque estadístico permitió triangular resultados: las variables que muestran asociación tanto en Spearman como en Chi-cuadrado son las candidatas más robustas para el modelado.

3.5 Definición de KPIs

A partir del análisis exploratorio y de correlaciones se definieron los siguientes indicadores clave de rendimiento para el cuadro de mando:

- Tasa de conversión global: porcentaje de contactos que resultan en contratación (11,3% en el período analizado).
- Tasa de conversión segmentada: desagregación por grupo de edad, ocupación, nivel educativo, estado civil, canal de contacto, mes del año y día de la semana.
- Tasa de conversión por historial: diferenciación según resultado de campañas previas (*poutcome*).
- Intensidad de contacto vs. resultado: relación entre número de contactos en la campaña y probabilidad de contratación.
- Indicadores macroeconómicos contextuales: evolución de la tasa de empleo, CPI, confianza del consumidor y euríbor en relación con la efectividad de las campañas.

3.6 Modelado predictivo

Se entrenaron tres configuraciones de modelos para estimar la probabilidad de contratación. Los tres comparten la misma partición de datos (80% entrenamiento, 20% test, muestreo estratificado, semilla 42) y se evaluaron tanto con umbral estándar de 0,5 como con umbral optimizado para maximizar el

F1-score de la clase positiva.

La siguiente tabla resume la configuración de cada modelo:

Modelo	Algoritmo	Configuración clave
LR Completa	Regresión logística	Regularización L2, class_weight=balanced, one-hot encoding (drop_first)
XGBoost	Gradient Boosting	1.000 estimadores, lr=0,05, max_depth=5, subsample=0,8, scale_pos_weight, early stopping
LR Clean	Regresión logística	Misma config. que LR pero sin variables <i>month</i> y <i>day_of_week</i>

La regresión logística se eligió como modelo base por su interpretabilidad y adecuación a la clasificación binaria. El XGBoost se incluyó como referencia de mayor capacidad, capturando relaciones no lineales e interacciones entre variables. La variante "clean" busca evaluar si las variables temporales (mes y día) aportan señal genuina o introducen ruido.

Las métricas de evaluación fueron precisión, recall (sensibilidad), F1-score, exactitud global (accuracy) y área bajo la curva ROC (ROC-AUC). En problemas desbalanceados, el

umbral por defecto de 0,5 rara vez ofrece el mejor compromiso entre precisión y sensibilidad, por lo que se optimizó el umbral para cada modelo.

3.7 Cuadro de mando ejecutivo

El cuadro de mando se diseñó en Power BI para comunicar los resultados a la capa ejecutiva de la entidad. Se alimenta de ficheros CSV exportados desde Python:

- Dataset limpio completo para análisis interactivo.
- Tablas de correlaciones (Spearman y Chi-cuadrado) para dimensionamiento de factores.
- Perfil comparativo de clientes contratantes vs. no contratantes.
- Métricas comparativas de modelos (matrices de confusión, F1, ROC-AUC).
- Datos macroeconómicos para contextualización temporal.

El diseño prioriza claridad visual, filtrado interactivo y jerarquía de información, de modo que el usuario pueda navegar desde los KPIs agregados hasta el detalle por segmento o período.

4. RESULTADOS

4.1 Hallazgos del análisis exploratorio

El análisis reveló diferencias marcadas en la tasa de conversión según las distintas dimensiones del dataset. La tasa de conversión global es del 11,3%. A continuación se presentan los principales hallazgos por dimensión.

Conversión por grupo de edad:

Grupo de edad	Tasa de conversión	Volumen (n)
65+	47,2%	Bajo
17-25	23,9%	Bajo
56-65	13,5%	Medio
26-35	12,1%	Alto
46-55	8,6%	Alto
36-45	8,6%	Muy alto

Este patrón sugiere que la propensión al ahorro a plazo está vinculada a etapas vitales concretas: inicio de vida financiera en los jóvenes, acumulación de capital y menor aversión al compromiso temporal en los mayores.

Conversión por ocupación y canal:

Dimensión	Segmento	Tasa conv.	Detalle
Ocupación	Estudiantes	31,4%	n=875, mayor tasa
Ocupación	Jubilados	25,2%	n=1.720
Ocupación	Desempleados	14,2%	n=1.014
Ocupación	Admin.	13,0%	n=10.422, mayor volumen
Ocupación	Construcción	6,9%	n=9.254, menor tasa
Canal	Teléfono móvil	14,7%	63,5% de interacciones
Canal	Teléfono fijo	5,2%	Casi 3x menos efectivo

La estacionalidad es un factor determinante. Marzo alcanza una tasa del 50,5%, seguido de diciembre (48,9%), septiembre (44,9%) y octubre (43,9%). En contraste, mayo, que concentra el mayor volumen de llamadas, registra apenas un 6,4%. Por día de la semana, jueves (12,1%) y martes (11,8%) superan ligeramente al lunes (9,9%), aunque las diferencias son menos marcadas que las mensuales.

La duración de la llamada muestra una relación directa con la contratación:

Duración	Tasa de conversión
> 20 minutos	62,6%
10 - 20 minutos	46,2%
5 - 10 minutos	18,6%
3 - 5 minutos	10,8%
1 - 3 minutos	5,3%
< 1 minuto	0,0%

- El resultado de campañas previas (*poutcome*) es la variable con mayor poder discriminante a nivel descriptivo: los clientes que contrataron en una campaña anterior convierten al 65,1%, frente al 14,2% de quienes no lo hicieron y al 8,8% de quienes no tienen historial. El número de contactos en la campaña actual muestra una relación inversa: con un solo contacto la conversión es del 13,0%, cayendo progresivamente hasta el 3,1% con once o más contactos.
- Por nivel educativo, los titulados universitarios (13,7%) y quienes cursaron formación profesional (11,3%) superan a los niveles básicos (7,8-10,2%). Los solteros (14,0%) convierten más que los casados (10,2%) y divorciados (10,3%).
- Las variables de situación financiera mostraron escasa capacidad de diferenciación. La hipoteca (11,6% con vs. 10,9% sin) y el préstamo personal (10,9% vs. 11,3%) no presentan diferencias relevantes. El impago crediticio registra una conversión del 12,9% para quienes no tienen impago, pero solo el 5,2% para los registros "unknown", reforzando la hipótesis de que la ausencia de información en esta variable tiene significado propio.
- En el plano macroeconómico, se observa una relación inversa entre la tasa de variación del empleo y la contratación: los períodos con mayor deterioro laboral coinciden con tasas de conversión más altas. El euríbor a tres meses muestra un patrón similar. Estos resultados apuntan a un mecanismo de refugio financiero: en contextos de incertidumbre, los depósitos a plazo se perciben como una opción de ahorro segura. El índice de confianza del consumidor, con una V de Cramér de 0,382, confirma que el sentimiento económico de los hogares es un factor explicativo de primer orden.

4.2 Resultados de los modelos predictivos

La siguiente tabla compara el rendimiento de los tres modelos con umbral estándar (0,5) y umbral optimizado:

Modelo	ROC-AUC	Umbral ópt.	F1 (0,5)	F1 (ópt.)	Precisión (ópt.)	Recall (ópt.)
LR Completa	0,939	0,68	0,59	0,63	52%	79%
XGBoost	0,950	0,72	0,61	0,66	55%	82%
LR Clean	0,934	0,69	0,58	0,62	52%	76%

- La regresión logística con todas las variables alcanzó un ROC-AUC de 0,939. Con umbral 0,5, detecta el 90% de los contratantes (recall = 0,90), pero con una precisión del 44%, generando 1.064 falsos positivos de 1.903 clasificados como positivos. Al ajustar el umbral a 0,68, el F1-score mejora de 0,59 a 0,63, la precisión sube al 52% y la exactitud global pasa del 86% al 90%.
- El XGBoost obtuvo el mejor rendimiento global, con ROC-AUC de 0,950. Con umbral 0,5, su recall alcanza el 94% (detecta 875 de 928 casos positivos), el más alto de los tres modelos. Con el umbral óptimo de 0,72, el F1-score sube a 0,66.
- La regresión logística reducida (sin mes ni día de la semana) obtuvo un ROC-AUC de 0,934. El rendimiento ligeramente inferior confirma que las variables temporales aportan información marginal pero no despreciable.

4.3 Interpretación de los modelos

Los coeficientes de la regresión logística identifican las siguientes variables como las más influyentes:

- Peso positivo: mes de marzo, índice de precios al consumo, resultado exitoso de campañas previas (*poutcome=success*), mes de octubre, ocupaciones de jubilado y estudiante.
- Peso negativo: mes de mayo (coeficiente negativo más fuerte), tasa de variación del empleo, categoría "unknown" en *default*, mes de noviembre, ocupación de construcción.

En el XGBoost, la importancia de las variables sitúa al número de empleados en primer lugar, seguido de la duración de la llamada, la tasa de variación del empleo, el índice de confianza del consumidor y los meses de octubre y mayo. Que tres de las cinco variables más

importantes sean macroeconómicas refuerza la hipótesis de que el entorno económico pesa tanto o más que las características individuales del cliente.

La diferencia entre la regresión logística y el XGBoost es moderada: 1,1 puntos de ROC-AUC y 3 puntos de F1-score con umbral óptimo. Dado que la guía del proyecto solicita un modelo simple, la regresión logística es la opción más adecuada para esta memoria: interpretable, con coeficientes de lectura directa y rendimiento competitivo. El XGBoost sirve como referencia para cuantificar el margen de mejora disponible con técnicas más complejas.

La optimización del umbral demostró tener impacto real: en los tres modelos, mejoró el F1-score entre 3 y 6 puntos. En un escenario operativo, la elección del umbral dependerá del coste relativo de llamar a un cliente que no contratará frente al de no contactar a uno que sí lo habría hecho.

4.4 Cuadro de mando ejecutivo

El dashboard en Tableau consolida los resultados en un formato visual orientado a la decisión. Incluye:

- Tasa de conversión global y segmentada por las dimensiones principales (edad, ocupación, educación, canal, mes).
- Distribución temporal de la efectividad de las campañas.
- Perfil comparativo de clientes contratantes frente a no contratantes.
- Evolución macroeconómica en relación con los resultados de campaña.

Los datos se alimentan de ficheros CSV exportados desde Python, lo que permite actualizar el dashboard ante nuevas campañas sin requerir intervención técnica sobre el código analítico.

5. CONCLUSIONES Y DISCUSIÓN

5.1 Síntesis de hallazgos

- El análisis de más de 41.000 contactos telefónicos permite extraer conclusiones con respaldo cuantitativo suficiente. Los hallazgos principales se organizan en cuatro ejes:
- Perfil del cliente. No responde a un único patrón. Los segmentos con mayor tasa de conversión son mayores de 65 años (46,9%), estudiantes (31,4%) y jubilados (25,2%), lo que asocia la propensión al ahorro a plazo con etapas vitales concretas. Los solteros (14,0%) convierten más que los casados (10,2%), y los titulados universitarios (13,7%) superan a los niveles educativos básicos.
- Contexto macroeconómico. Resultó un factor explicativo de primer orden. El euríbor a tres meses y el número de empleados presentan las V de Cramér más altas (0,411) y ocupan las posiciones de mayor importancia en el XGBoost. La relación inversa entre deterioro económico y contratación apunta a un mecanismo de refugio financiero: en contextos de incertidumbre, los depósitos a plazo ganan atractivo relativo como instrumento seguro.
- Calidad de la interacción. La duración de la llamada (ρ de Spearman = 0,349; V de Cramér = 0,292) confirma que la calidad del contacto comercial es determinante. Las llamadas superiores a 10 minutos alcanzan tasas de conversión del 46-63%, frente al 0% de las inferiores a un minuto.
- Historial de campañas. Los clientes que ya contrataron en el pasado convierten al 65,1%, frente al 8,8% de quienes no tienen historial. El número de contactos en la campaña actual muestra rendimientos decrecientes: la conversión cae del 13,0% (1 contacto) al 3,1% (11+).

5.2 Sobre los modelos predictivos

- Los tres modelos alcanzan un rendimiento sólido, con ROC-AUC entre 0,934 y 0,950. Que la regresión logística obtenga resultados comparables a los del XGBoost confirma que, para este tipo de problema, la interpretabilidad no exige sacrificar capacidad predictiva de forma significativa.
- Ajustar el umbral de clasificación mejoró el F1-score en todos los casos. Con el umbral optimizado, la regresión logística alcanza un F1 de 0,63 y el XGBoost de 0,66.

La decisión sobre qué umbral aplicar en producción dependerá de un análisis coste-beneficio específico de la entidad.

- La variante sin mes y día de la semana rindió ligeramente menos (ROC-AUC de 0,934 frente a 0,939), lo que indica que la estacionalidad aporta algo de señal. La diferencia no es grande, pero justifica mantener estas variables.

5.3 Limitaciones

- El dataset corresponde a un período y mercado específicos (Portugal, 2008-2010). Los patrones están condicionados por la crisis financiera y no son directamente extrapolables a otros contextos.
- No existe un identificador único de cliente, lo que impide un análisis longitudinal completo de la trayectoria de contacto.
- La variable *duration*, altamente predictiva, no está disponible antes de la llamada. Los modelos que la incluyen obtienen métricas que sobreestiman el rendimiento en un escenario de uso real previo al contacto.
- El 20,9% de valores desconocidos en *default* compromete la fiabilidad de esta variable. Si el mecanismo de ausencia no es aleatorio, podría introducir sesgos no detectados.
- La evaluación se realizó sobre una partición interna del dataset, sin datos externos. No se dispuso de un conjunto de validación independiente para reforzar las garantías de generalización.

5.4 Recomendaciones estratégicas (corto-medio plazo)

A partir de los hallazgos del análisis, se formulan las siguientes recomendaciones para la optimización de futuras campañas de marketing directo:

1. **Segmentación prioritaria: concentrar los esfuerzos de contacto en los segmentos con mayor tasa de conversión demostrada:** mayores de 65 años, estudiantes, jubilados y solteros con educación universitaria. La diferencia entre un 46,9% y un 6,9% de conversión justifica la priorización.
2. **Canal preferente:** priorizar el teléfono móvil frente al fijo. La tasa de conversión del canal celular (14,7%) casi triplica la del fijo (5,2%), lo que sugiere mayor receptividad o disponibilidad del cliente.

3. **Optimización temporal:** concentrar las campañas en los meses de mayor efectividad (marzo, septiembre, octubre, diciembre) y reducir la intensidad en mayo, que pese a concentrar el mayor volumen de llamadas registra la menor tasa de conversión (6,4%).
4. **Gestión de la intensidad de contacto:** limitar el número de contactos por cliente. La conversión cae de forma progresiva con cada contacto adicional, y superar los cinco contactos reduce la efectividad al 6,3%. Un sistema de scoring podría establecer umbrales dinámicos de abandono.
5. **Fidelización de cartera:** invertir en el seguimiento de clientes que contrataron previamente. Con una tasa de reconversión del 65,1%, la retención ofrece rendimientos muy superiores a la captación en frío (8,8%).
6. **Formación del equipo comercial:** la relación directa entre duración de llamada y contratación sugiere que las interacciones de calidad, con argumentarios adaptados al perfil del cliente, son más efectivas que los contactos breves y masivos.
7. **Monitorización del entorno macro:** incorporar indicadores macroeconómicos al sistema de scoring. Los períodos de incertidumbre económica favorecen la contratación de depósitos, lo que debería intensificar (no reducir) el esfuerzo comercial en esos contextos.
8. **Segmentación por comportamiento macroeconómico para venta cruzada:** Los datos revelan que el contexto económico no afecta a todos los clientes por igual. Una segmentación basada en la sensibilidad al euríbor y la capacidad de ahorro permitiría diferenciar perfiles con estrategias distintas: clientes con deuda variable y ratio de endeudamiento elevado, cuya capacidad de ahorro se anula cuando los tipos suben, deberían excluirse del modelo de precisión para evitar costes de contacto sin retorno. En contraste, clientes con saldos elevados, sin deuda variable y perfil conservador (especialmente mayores de 45 años) constituyen el segmento de mayor valor en escenarios de tipos altos, donde buscan refugio y seguridad. Para ahorradores pasivos con nómina estable y ahorros moderados, la estrategia óptima es la captación masiva en entornos de tipos bajos, utilizando el modelo de recall para maximizar el volumen de captación. Esta segmentación permitiría además orientar la venta cruzada de otros productos financieros según la coyuntura: depósitos en fases de incertidumbre, productos de inversión en fases de recuperación.
9. **Captación y análisis de datos de campañas:** El dataset actual no incluye información sobre el coste por contacto, el margen del producto ni la tasa de retención

posterior. Incorporar estas variables permitiría calcular el retorno real de cada campaña y construir un modelo de optimización del coste por adquisición (CPA). La medición sistemática de la efectividad por campaña, canal y segmento proporcionaría la base cuantitativa para validar si las recomendaciones derivadas de este análisis mejoran los resultados de forma sostenida.

10. **Estrategia de lead nurturing mediante newsletter:** El 96,3% de los clientes contactados no tenía historial de campañas previas, y la tasa de conversión de quienes sí lo tienen (14,2%) casi duplica la de quienes carecen de él (8,8%). Crear un canal de comunicación periódica (newsletter de contenido financiero, alertas de mercado, actualizaciones del euríbor) permitiría cultivar la relación con el cliente entre campañas, generar familiaridad con la marca y construir un historial de interacciones que alimente al modelo predictivo con datos de comportamiento digital (aperturas, clics, respuestas). Este enfoque de *lead nurturing* reduciría la dependencia del contacto en frío y aumentaría la efectividad de las campañas posteriores.

5.5 Oportunidades de desarrollo a futuro (medio-largo plazo)

- La incorporación de datos más recientes permitiría evaluar si los patrones se mantienen en un contexto económico diferente.
- Disponer de un identificador de cliente abriría la vía a modelos de valor de vida (CLV) y análisis de secuencias de contacto óptimas.
- Entrenar modelos sin la variable *duration* aportaría una estimación más realista del rendimiento en producción.
- La aplicación de técnicas de sobremuestreo (SMOTE) o submuestreo podría compararse con la estrategia de ponderación de clases adoptada aquí.
- La automatización del pipeline, desde la extracción de datos hasta la actualización del dashboard, convertiría este análisis puntual en un sistema de monitorización continua de la efectividad comercial.
- Desarrollar un modelo de segmentación dinámica que clasifique la base de clientes en perfiles de comportamiento macroeconómico (sensibilidad al euríbor, capacidad de ahorro, propensión al riesgo), de modo que las campañas se adapten automáticamente al ciclo económico.

- Implementar un sistema de medición de campañas de extremo a extremo que incluya coste por contacto, margen por producto contratado y valor de vida del cliente, cerrando el ciclo entre predicción y validación de resultados.

6. BIBLIOGRAFÍA

- Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, 62, 22-31.
- UCI Machine Learning Repository. Bank Marketing Data Set. <https://archive.ics.uci.edu/ml/datasets/Bank+Marketing>
- Banco de Portugal (BPstat). Indicadores económicos y financieros. <https://bpstat.bportugal.pt/>
- Comisión Europea, DG ECFIN. Índice de confianza del consumidor. Business and Consumer Surveys.
- Instituto Nacional de Estadística de Portugal (INE). Índice de precios al consumo. <https://www.ine.pt/>
- European Money Markets Institute (EMMI). Euribor historical data. <https://www.emmi-benchmarks.eu/>